



Universidade Federal
de São João del-Rei

Departamento de Ciência da Computação

Vítor Augusto Niess Soares Fonseca

Relatório Algoritmo Genético Real

São João del-Rei, Abril de 2024

Sumário

1	Introdução	3
2	Metodologia	3
2.1	Representação dos Indivíduos	3
2.2	Estratégia de Seleção	3
2.3	Cruzamento	4
2.4	Mutação	4
2.5	Elitismo	5
3	Resultados e Discussão	5
3.1	Variação da Taxa de Mutação	5
3.2	Variação da Taxa de Cruzamento	7
3.3	Variação do Tamanho da População	8
3.4	Variação do Número de Gerações	10
3.5	Comparação dos Algoritmos BLX- α e BLX- $\alpha\beta$	12
4	Considerações Finais	12

1 Introdução

Os algoritmos genéticos (AGs) são técnicas de otimização inspiradas no processo de seleção natural que ocorre na evolução biológica. Eles têm sido amplamente aplicados em uma variedade de domínios, desde problemas de otimização até aprendizado de máquina e design de sistemas complexos. A essência dos algoritmos genéticos reside na aplicação de operadores genéticos, como seleção, cruzamento e mutação, em uma população de indivíduos candidatos, a fim de buscar soluções ótimas ou subótimas para um determinado problema.

Uma parte fundamental dos algoritmos genéticos é o processo de seleção de pais, no qual indivíduos são escolhidos para reprodução com base em sua aptidão em relação ao problema em questão. A eficácia do método de seleção de pais pode ter um impacto significativo no desempenho e na convergência do algoritmo genético. Neste trabalho, foi utilizado a Seleção Proporcional à Aptidão (Roulette Wheel Selection).

Além disso, também analisamos dois métodos de cruzamento frequentemente empregados: o BLX+ e o BLX-. O método BLX+ é uma extensão do cruzamento uniforme que permite a geração de novos indivíduos dentro de uma faixa definida, enquanto o BLX- aprimora essa abordagem, introduzindo uma zona intermediária entre os pais para aumentar a diversidade genética na descendência. Ambos os métodos desempenham um papel crucial na exploração do espaço de busca e na geração de novas soluções.

Este relatório apresenta uma análise comparativa entre os algoritmos BLX+ e o BLX- em termos de convergência, eficiência computacional e robustez em face de diferentes tipos de problemas. Ao examinar esses métodos, buscamos fornecer *insights* valiosos para a seleção adequada do método de cruzamento em algoritmos genéticos, contribuindo assim para o avanço e aprimoramento dessa importante área de pesquisa.

2 Metodologia

Nesta seção, serão demonstradas as estratégias metodológicas adotadas para alcançar os objetivos propostos. Como mencionado, o algoritmo desenvolvido visa obter o menor valor (minimização) de $f(x)$ da seguinte função:

$$f(x) = -20 \times e^{-0,2 \times \sqrt{\frac{1}{n} \times \sum x_i^2}} - e^{\frac{1}{n} \times \sum \cos(2 \times \pi \times x_i)} + 20 + e$$

Sendo que n é o número de variáveis a serem ajustadas.

2.1 Representação dos Indivíduos

Para problemas de ajuste de parâmetros, podemos usar um vetor de números reais, que reflete exatamente o conjunto de variáveis que queremos encontrar.

No caso de $n = 3$ (representação escolhida para o presente trabalho) temos três variáveis a serem ajustadas, portanto, o indivíduo é um vetor de duas posições do tipo real e suas posições são aplicadas diretamente como parâmetros da função objetivo.

2.2 Estratégia de Seleção

Como mencionado, para determinar quais indivíduos da geração iriam cruzar para gerar novos filhos, foi utilizada a Seleção Proporcional à Aptidão, também conhecida como *Roulette Wheel Selection* (Seleção da Roda da Roleta), é um método comumente utilizado para selecionar

pais em algoritmos genéticos. Este método é baseado na atribuição de probabilidades de seleção a cada indivíduo da população com base em sua aptidão relativa em relação aos demais indivíduos.

O processo de Seleção Proporcional à Aptidão pode ser dividido em etapas distintas:

- Avaliação da Aptidão: Inicialmente, cada indivíduo na população é avaliado em relação ao problema em questão, atribuindo-se a ele um valor de aptidão que reflete o quão bem ele se adapta à solução do problema.
- Cálculo das Probabilidades de Seleção: Com base nos valores de aptidão de cada indivíduo, são calculadas as probabilidades de seleção. Isso é geralmente feito dividindo-se a aptidão de cada indivíduo pela soma total das aptidões de todos os indivíduos na população, resultando em uma distribuição de probabilidades proporcional à aptidão.
- Seleção dos Pais: Uma vez que as probabilidades de seleção foram calculadas, o processo de seleção é realizado. Isso pode ser visualizado como uma roda de roleta, na qual cada indivíduo possui uma fatia proporcional ao seu valor de aptidão. A roda é girada aleatoriamente e os pais são selecionados com base no ponto onde a "bola" para.
- Repetição do Processo: O processo de seleção é repetido até que todos os pais necessários para a reprodução tenham sido selecionados.

2.3 Cruzamento

Os métodos de cruzamento comparados, BLX- α e BLX- $\alpha\beta$ são amplamente utilizados em algoritmos genéticos para gerar novas soluções a partir de pares de indivíduos pais. Ambos os métodos são variações do cruzamento uniforme, mas com a introdução de um parâmetro de extensão, α , e, no caso do BLX- $\alpha\beta$, um segundo parâmetro, β .

O processo de cruzamento BLX- α pode ser descrito da seguinte forma:

- Para cada variável de decisão, x_i , do par de pais, determina-se o intervalo de cruzamento entre $[x_{min}, x_{max}]$, onde x_{min} e x_{max} são as menores e maiores coordenadas entre os pais para a variável x_i , respectivamente.
- Calcula-se a diferença $\Delta = x_{max} - x_{min}$.
- Gera-se um novo valor para a variável x_i dentro do intervalo estendido $[x_{min} - \alpha \cdot \Delta, x_{max} + \alpha \cdot \Delta]$. O valor é escolhido de forma aleatória e uniforme dentro deste intervalo.

O processo de cruzamento BLX- $\alpha\beta$ é semelhante ao BLX- α , mas com a adição de um fator de extensão adicional, β , para aumentar a diversidade genética. O intervalo de cruzamento é estendido para $[x_{min} - \beta \cdot \Delta, x_{max} + \beta \cdot \Delta]$.

Esses métodos de cruzamento são eficazes para explorar o espaço de busca e gerar novas soluções, permitindo uma diversificação controlada das características dos indivíduos descendentes.

2.4 Mutação

A operação de mutação tem o papel de diversificação da população, muitas vezes os indivíduos ficam presos a ótimos locais e precisam de uma perturbação maior para que seja possível escapar desses locais.

Durante o desenvolvimento do algoritmo, uma taxa de mutação de 0,5% foi escolhida para cada gene. Essa taxa foi selecionada após experimentação e análise prévia, visando encontrar um equilíbrio entre a diversidade genética da população e a convergência para soluções ótimas.

2.5 Elitismo

O elitismo é uma estratégia de manutenção da(s) melhor(es) solução(ções) através das gerações.

No âmbito deste trabalho, ela se mostra presente por meio da passagem do melhor indivíduo da geração para a próxima.

3 Resultados e Discussão

Nesta seção, apresentamos os resultados obtidos a partir da execução do algoritmo genético com diferentes configurações de parâmetros e métodos de cruzamento. Para avaliar o desempenho do algoritmo, realizamos uma série de experimentos variando as seguintes configurações:

- Taxa de Mutação: 1%, 5%, 10%;
- Taxa de Cruzamento: 60%, 80%, 100%;
- Tamanho da População: 25, 50, 100;
- Número de Gerações: 25, 50, 100;
- Métodos de Cruzamento: $BLX-\alpha$ e $BLX-\alpha\beta$;
- Com ou Sem Elitismo;

Essas alterações foram realizadas com o objetivo de avaliar o impacto de diferentes configurações de parâmetros e métodos de cruzamento no desempenho e na convergência do algoritmo genético. Para cada combinação de configurações, realizamos múltiplas execuções do algoritmo e registramos os resultados obtidos em termos de convergência, eficiência computacional e qualidade das soluções encontradas.

3.1 Variação da Taxa de Mutação

Nesta seção, analisamos os resultados obtidos ao variar a taxa de mutação no algoritmo genético. Os testes foram conduzidos com taxas de mutação de 1%, 5% e 10%. Observamos que, em geral, houve melhorias no desempenho do algoritmo à medida que a taxa de mutação aumentava para ambos os métodos de cruzamento $BLX-\alpha$ e $BLX-\alpha\beta$.

Para uma taxa de mutação de 1%, o algoritmo mostrou convergência mais lenta e menor diversidade genética, resultando em uma exploração menos eficiente do espaço de busca. Consequentemente, as soluções encontradas tenderam a estagnar em ótimos locais subótimos.

Ao aumentar a taxa de mutação para 5%, observamos uma melhoria significativa no desempenho do algoritmo. A maior taxa de mutação permitiu uma maior diversificação da população, facilitando a exploração de diferentes regiões do espaço de busca. Isso levou a uma convergência mais rápida e a soluções de maior qualidade em comparação com a taxa de mutação de 1%.

Aumentar ainda mais a taxa de mutação para 10% resultou em um desempenho ainda melhor do algoritmo. Com uma taxa de mutação mais elevada, a diversidade genética na população foi ainda mais ampliada, possibilitando uma exploração mais abrangente do espaço de busca. Consequentemente, observamos uma convergência mais rápida e soluções de melhor qualidade em comparação com as taxas de mutação de 1% e 5%.

Para uma melhor visualização dos resultados, serão apresentados gráficos que demonstram a evolução da aptidão da população ao longo das gerações para cada uma das taxas de cruzamento testadas. Esses gráficos ajudarão a destacar as diferenças de desempenho entre as diferentes configurações de taxa de cruzamento e métodos de cruzamento.

Em resumo, os testes demonstraram que, até o valor de 10%, a taxa de mutação exerceu um impacto positivo no desempenho do algoritmo genético para ambos os métodos de cruzamento. Taxas de mutação mais altas promoveram uma maior diversificação genética na população, levando a uma convergência mais rápida e a soluções de melhor qualidade.




Figura 1: Gráfico com taxa de mutação de %.

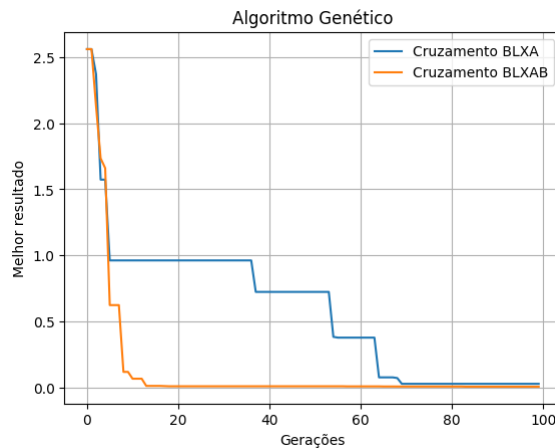


Figura 2: Gráfico com taxa de mutação de 5%.

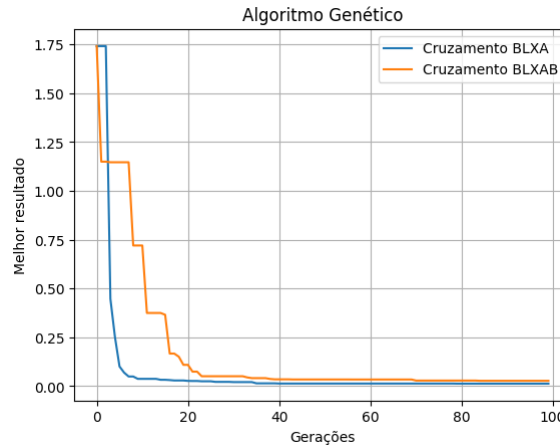


Figura 3: Gráfico com taxa de mutação de 10%.

3.2 Variação da Taxa de Cruzamento

Nesta seção, examinamos os resultados obtidos ao variar a taxa de cruzamento no algoritmo genético. Os testes foram conduzidos com taxas de cruzamento de 60%, 80% e 100%. Observamos que, assim como com a taxa de mutação, houve melhorias no desempenho do algoritmo à medida que a taxa de cruzamento aumentava para ambos os métodos de cruzamento BLX- α e BLX- $\alpha\beta$.

Inicialmente, observamos que uma taxa de cruzamento de 60% resultou em um desempenho aceitável do algoritmo. No entanto, a baixa taxa de cruzamento limitou a diversidade genética na população, o que pode levar a uma convergência prematura e a soluções subótimas.

Ao aumentar a taxa de cruzamento para 80%, observamos uma melhoria significativa no desempenho do algoritmo. A taxa mais alta de cruzamento permitiu uma maior recombinação genética entre os indivíduos, o que facilitou a exploração de novas áreas do espaço de busca. Isso resultou em uma convergência mais rápida e a soluções de melhor qualidade em comparação com a taxa de cruzamento de 60%.

Aumentar ainda mais a taxa de cruzamento para 100% levou a um desempenho ainda melhor do algoritmo. Com uma taxa de cruzamento mais alta, todos os indivíduos na população foram cruzados, resultando em uma diversificação genética máxima. Isso proporcionou uma exploração abrangente do espaço de busca e uma convergência ainda mais rápida em comparação com as taxas de cruzamento de 60% e 80%.

Assim como os testes anteriores, para uma melhor visualização dos resultados, serão apresentados gráficos que demonstram a evolução da aptidão da população ao longo das gerações para cada uma das taxas de cruzamento testadas.

Em resumo, os resultados indicam que, assim como a taxa de mutação, a taxa de cruzamento exerceu um impacto positivo no desempenho do algoritmo genético para ambos os métodos de cruzamento, sendo que maiores taxas de cruzamento promoveram uma convergência mais rápida e soluções de melhor qualidade.




Figura 4: Gráfico com taxa de cruzamento de 60%.




Figura 5: Gráfico com taxa de cruzamento de 80%.




Figura 6: Gráfico com taxa de cruzamento de 100%.

3.3 Variação do Tamanho da População

Nesta seção, investigamos os resultados obtidos ao variar o tamanho da população no algoritmo genético. Os testes foram realizados com tamanhos de população de 25, 50 e 100 indivíduos. Observamos que, assim como com a taxa de mutação e a taxa de cruzamento, houve melhorias no desempenho do algoritmo à medida que o tamanho da população aumentava, para

ambos os métodos de cruzamento BLX- α e BLX- $\alpha\beta$.

Iniciando com uma população de 25 indivíduos, observamos que o algoritmo apresentou resultados decentes. No entanto, devido ao tamanho pequeno da população, houve uma limitação na diversidade genética, o que pode prejudicar a capacidade do algoritmo de explorar efetivamente o espaço de busca.

Ao aumentar o tamanho da população para 50 indivíduos, notamos uma melhoria significativa no desempenho do algoritmo. Com um número maior de indivíduos na população, houve uma maior diversificação genética, permitindo uma exploração mais ampla do espaço de busca. Isso resultou em uma convergência mais rápida e em soluções de melhor qualidade em comparação com a população de 25 indivíduos.

Aumentar ainda mais o tamanho da população para 100 indivíduos levou a um desempenho ainda melhor do algoritmo. Com uma população maior, a diversidade genética foi ainda mais ampliada, facilitando uma exploração mais abrangente do espaço de busca. No entanto, observamos que, a partir de uma população de 50 indivíduos, já foram encontrados bons resultados, indicando que um tamanho de população maior pode oferecer benefícios adicionais, mas pode não ser necessário para obter resultados satisfatórios.

Para uma melhor visualização dos resultados, serão apresentados gráficos que demonstram a evolução da aptidão da população ao longo das gerações para cada um dos tamanhos de população testados. Esses gráficos ajudarão a destacar as diferenças de desempenho entre as diferentes configurações de tamanho de população e métodos de cruzamento.

Em resumo, os resultados indicam que, assim como a taxa de mutação e a taxa de cruzamento, o tamanho da população exerceu um impacto positivo no desempenho do algoritmo genético, com melhores resultados sendo encontrados a partir de uma população de 50 indivíduos, embora um tamanho de população maior possa oferecer benefícios adicionais.

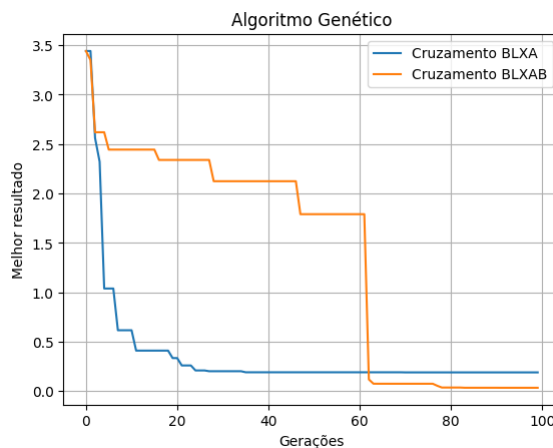


Figura 7: Gráfico com tamanho de população 25.

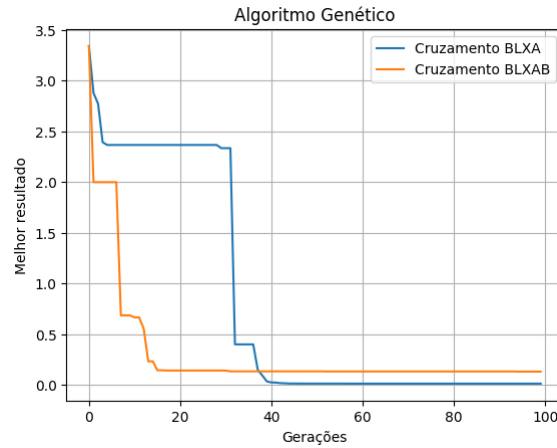


Figura 8: Gráfico com tamanho de população 50.




Figura 9: Gráfico com tamanho de população 100.

3.4 Variação do Número de Gerações

Nesta seção, exploramos os resultados obtidos ao variar o número de gerações no algoritmo genético. Os testes foram conduzidos com 25, 50 e 100 gerações. Observamos que, assim como com a taxa de mutação, a taxa de cruzamento e o tamanho da população, houve melhorias no desempenho do algoritmo à medida que o número de gerações aumentava, para ambos os métodos de cruzamento $BLX-\alpha$ e $BLX-\alpha\beta$.

Começando com 25 gerações, observamos que o algoritmo apresentou resultados decentes. No entanto, devido ao número limitado de gerações, houve uma limitação na capacidade do algoritmo de explorar completamente o espaço de busca, o que pode resultar em soluções subótimas.

Ao aumentar o número de gerações para 50, notamos uma melhoria significativa no desempenho do algoritmo. Com um maior número de gerações, as populações tiveram mais tempo para se adaptar e evoluir, permitindo uma exploração mais completa do espaço de busca. Isso resultou em uma convergência mais rápida e em soluções de melhor qualidade em comparação com 25 gerações.

Aumentar ainda mais o número de gerações para 100 resultou em um desempenho ainda melhor do algoritmo. Com mais gerações, as populações tiveram ainda mais tempo para se adaptar e explorar o espaço de busca, levando a uma convergência mais rápida e a soluções de melhor qualidade. No entanto, observamos que, a partir de 50 gerações, os resultados já se

aproximam dos ótimos, indicando que um número maior de gerações pode oferecer benefícios adicionais, mas pode não ser necessário para obter resultados satisfatórios.

Para uma melhor visualização dos resultados, serão apresentados gráficos que demonstram a evolução da aptidão da população ao longo das gerações para cada um dos números de gerações testados. Esses gráficos ajudarão a destacar as diferenças de desempenho entre as diferentes configurações de número de gerações e métodos de cruzamento.

Em resumo, os resultados indicam que, quanto mais gerações as populações têm para se adaptarem, melhores são os resultados, com resultados satisfatórios já sendo alcançados a partir de 50 gerações.




Figura 10: Gráfico com número de gerações em 25.

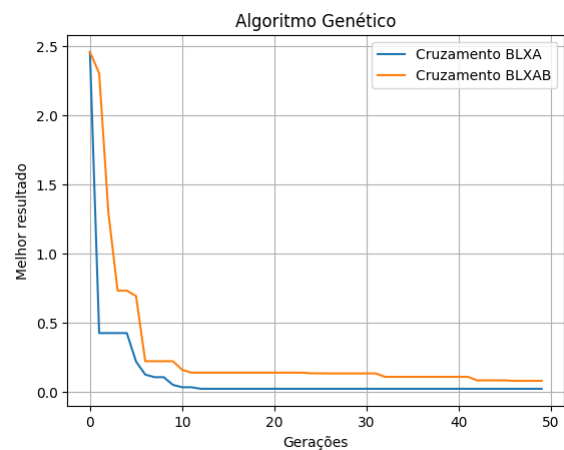


Figura 11: Gráfico com número de gerações em 50.




Figura 12: Gráfico com número de gerações em 100.

3.5 Comparação dos Algoritmos BLX- α e BLX- $\alpha\beta$

Nesta seção, comparamos os resultados obtidos ao utilizar os métodos de cruzamento BLX- α e BLX- $\alpha\beta$ no algoritmo genético. Em todos os testes realizados, ambos os métodos se mostraram eficientes na geração de novas soluções e na melhoria do desempenho do algoritmo.

No entanto, observamos algumas diferenças entre os dois métodos. O BLX- α mostrou uma maior variação de valores durante a busca, resultando em uma exploração mais diversificada do espaço de busca. Por outro lado, o BLX- $\alpha\beta$ mostrou uma melhoria mais linear dos resultados ao longo das gerações, indicando uma adaptação mais suave e consistente das populações ao longo do tempo.

Essas diferenças sugerem que o BLX- α pode ser mais adequado em cenários onde uma exploração mais diversificada do espaço de busca é desejada, enquanto o BLX- $\alpha\beta$ pode ser mais eficaz em situações que exigem uma adaptação mais gradual e consistente das populações.

4 Considerações Finais

Em resumo, os experimentos realizados proporcionaram um aprendizado valioso sobre a influência dos diferentes parâmetros e métodos no desempenho dos algoritmos genéticos. A variação da taxa de mutação, taxa de cruzamento, tamanho da população, número de gerações e métodos de cruzamento revelou insights cruciais sobre como esses fatores afetam a convergência e eficácia do algoritmo.

Através desses experimentos, compreendemos melhor a importância de adaptar as configurações do algoritmo genético de acordo com as características específicas do problema em questão. A escolha adequada de parâmetros e métodos pode influenciar significativamente a eficiência e a qualidade das soluções obtidas.

Portanto, este estudo ressalta a importância do entendimento profundo dos algoritmos genéticos e da habilidade de ajustar suas configurações para atender às demandas de diferentes problemas de otimização. Essa capacidade de adaptação e aprendizado contínuo é essencial para o sucesso na resolução de problemas complexos e dinâmicos.

Em conclusão, os resultados obtidos proporcionaram um valioso aprendizado sobre a aplicação e otimização de algoritmos genéticos, destacando a importância da experimentação e análise cuidadosa para o desenvolvimento de soluções eficazes em uma variedade de domínios.